1. 最小二乘回归函数（基于均方误差最小化来进行模型的方法称"最小二乘法"

$(w^*, b^*) = \arg\min_{(w,b)} (f(x_i) - y_i)^2$

$= \arg\min_{(w,b)} \sum_{i=1}^{m} (y_i - w x_i - b)^2$

X^TX可逆时，最小二乘法最优解：

$\hat{w}^* = (X^TX)^{-1}X^Ty$

第三章 线性模型

1. 在多元线性回归问题中，可用多种方法求解回归函数

$f(x_i) = w^T x_i + b$

$$w \in \mathrm{R}^{d\times 1}, x \in \mathrm{R}^{d\times 1}, b \in \mathrm{R}$$

的系数及偏置。令样本矩阵的增广矩阵为

$$X = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1d} & 1 \\ x_{21} & x_{22} & \cdots & x_{2d} & 1 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ x_{m1} & x_{m2} & \cdots & x_{md} & 1 \end{bmatrix}$$

请写出最小二乘法求解的目标函数及当协方差矩阵 $X^T X$ 可逆时，最小二乘法的最优解。

2. 在对数几率回归（或称为逻辑斯蒂回归）方法中，用Sigmoid函数

$$f(x) = \frac{1}{1+e^{-x}}$$

估计样本的后验类属概率。在二类问题中，假设用{0,1}两个符号表示标签。请你写出对数几率回归方法中，属于"1"类的概率与属于"0"类的概率公式。并写出使用极大似然法估计概率中参数的过程及相应的目标函数。

2. $P(y=1|x) = \frac{e^{wx+b}}{1+e^{wx+b}}$

$P(y=0|x) = \frac{1}{1+e^{wx+b}}$

$l(w,b) = \sum_{j=1}^{m} \ln p(y_j | x_j; w, b)$

$p(y_j | x_j; w, b) = p_1(\hat{x}_j; \beta)^{y_j} p_0(\hat{x}_j; \beta)^{1-y_i}$

3. 在二类分类问题中，Fisher线性判别法将样本投影到具有最大可分性的一维空间上。令 $w \in \mathrm{R}^{d\times 1}$ 表示投影方向，$x_i \in \mathrm{R}^{d\times 1}, i \in \{1,2,...,m\}$ 表示第 i 个样本向量，$\mu_l \in \mathrm{R}^{d\times 1}, \Sigma_l \in \mathrm{R}^{d\times d}, l \in \{0,1\}$ 分别表示第 l 类的均值和协方差矩阵，请写出投影后的类内散度矩阵及类间散度矩阵，并且写出目标函数广义瑞丽商。

类内散度矩阵：

$S_w = \Sigma_0 + \Sigma_1$

$= \sum_{x \in X_0} (x-\mu_0)(x-\mu_0)^T + \sum_{x \in X_1} (x-\mu_1)(x-\mu_1)^T$

类间 $S_b = (\mu_0-\mu_1)(\mu_0-\mu_1)^T$

4. （续上一题），请写出线性判别分析的模型，并使用拉格朗日法求解模型（写出拉格朗日法的求解过程及相应的解）。

LDA

$J = \frac{w^T S_b w}{w^T S_w w}$

$\min -w^T S_b w$

s.t. $w^T S_w w = 1$

拉格朗日：

$L(w) = -w^T S_b w + \lambda(w^T S_w w - 1)$

$\frac{\partial L(w)}{\partial w} = -2S_b w + 2\lambda S_w w = 0$

$S_b w = \lambda S_w w$

$S_b w = (\mu_0-\mu_1)\lambda$

又：S_b的方向恒为 $\mu_0-\mu_1$

$w(\mu_0-\mu_1) = \alpha S_w w$

$\therefore w = S_w^{-1}(\mu_0-\mu_1)$

5. 请列举解决多分类问题的策略有哪三种，并简述其概念。

一对一：将N个类别两两配对，从而产生N(N-1)/2个二分类任务

一对其余：每次将一个类的样例作为正例、所有其他类的样例作为反例来训练N个分类器

多对多：每次将若干个类作为正类，若干个其他类作为反类

6. 请简要阐述列别不平衡问题，并列举至少三种解决策略.

列别不平衡就是指分类任务中不同类别的训练样例数目差别很大的情况。

解决策略：

第一类是直接对训练集里的反类样例进行"欠采样"，即去除一些反例使得正例、反例数目接近，然后再进行学习。

第二类是对训练集里的正类样例进行"过采样"，即增加一些正例使得正、反例数目接近，然后再进行学习。

第三类是直接基于原始训练集进行学习，但在用训练好的分类器进行预测时，将式（）嵌入到其决策过程中，称为"阈值移动"。

第四章 决策树

1.决策树是基于（树）结构来进行决策的，包含的结点类型有（根结点）、（内部

2.决策树的生成是一个递归过程，请简要叙述递归返回条件（至少三种）

（1）当前结点包含的样本全属于同一类别，无需划分

（2）当前属性集为空，或是所有样本在所有属性上取值相同，无法划分

（3）当前结点包含的样本集合为空，不能划分

3.决策树的选择最优属性的准则有信息增益、增益率、基尼指数等。一般而言，属性的信息增益越大，说明属性来进行划分所获得的纯度提升越大。

请你写出信息增益的计算公式，并指出公式中每个符号代表的含义。并写出如何按照信息增益选择属性。

同样地，请你写出信息增益率、基尼指数的公式及含义，及选择属性的方式。

4.决策树学习算法防止过拟合的方式有（预剪枝）（后剪枝）等策略，这些策略是

5.决策树形成的分类边界的明显特点是（轴平行），即它的分类边界由若干个（与

第六章 支持向量机

一：选择题（2分/题）

1. 支持向量机模型的建模原理是最大化所有样本的（B）间隔。

A．平均 B. 最小 C. 任意 D. 最大

2. 软间隔线性支持向量机是为了处理（B）类型的数据。

A 线性可分 B 线性不可分 C 非线性可分 D 非线性不可分

3. 引入核函数的目的是为了处理（D）类型的数据。
A 非线性可分 B 非线性 C 非线性不可分 D 线性不可分

4. KKT条件中要求（B）与其拉格朗日乘子的积等于0.
A 等式约束 B 不等式约束 C 目标函数 D 拉格朗日函数

5. （C）是对偶问题与原始问题解等价的充要条件。
A 拉格朗日 B 极值法 C KKT条件 D核变换

二：简答题

1. 请你写出支持向量机的基本型，并阐述目标函数和约束条件的含义。（20分）

2. 请你写出软间隔支持向量机模型，并阐述目标函数和约束条件的含义。（20分）

3. 请你写出软间隔支持向量机的拉格朗日函数（10分）；KKT条件（10分）；对偶问题的模型（20分），以及写出“如何判断哪一个变量最违反KKT条件”的方法（10分）。

第七章 贝叶斯分类器

1.为什么贝叶斯分类器被称为最优分类器？

2.请写出条件风险的概念。

3.请写出在0-1损失意义下，贝叶斯最优分类器的公式。

4朴素贝叶斯分类器的假设是（ ）.

属性条件独立性假设：对已知类别，假设所有属性相互独立。换言之，假设每个属性独立地对分类结果发生影响。

，正则项是其五范数；当假设其分布为（拉普拉斯分布）时，正则项是其一范数。

第八章 集成学习

1.请简述集成学习的概念。

集成学习通过构建并结合多个学习器来完成学习任务

2.集成学习的个体学习器既要有一定的（准确性），又要有一定的（差异性）。

3.Adaboost算法属于（加性）模型，损失函数是（ ），分类器的权重更新公式是()

4.Boosting算法要求基学习器能对特定的数据分布进行学习，可通过（重赋权法）与（重采样法）两种方法实现。

5.从偏差-方差分解的角度看，Boosting方法降低（偏差），Bagging方法降低（方

6.请简要叙述Bagging算法。

给定一个大小为n的训练集D，Bagging算法从中均匀、有放回地（即使用自助抽样法）选出m个大小为n'的子集Di，作为新的训练集。在这m个训练集上使用分类、回归等算法，则可得到m个模型，再通过取平均值、取多数票等方法，即可得到Bagging的结果

7.随机森林在bagging的基础上，引入了（随机属性）选择机制。

8.集成学习的结合策略有哪些？

9.请列出混淆矩阵，并写出几种多样性度量的公式。

10．多样性增强的方法有哪些？

数据样本扰动、输入属性扰动、输出属性扰动、算法参数扰动

第十章 降维与度量学习

1.高维空间对机器学习方法带来哪些挑战？(至少两种)

数据样本稀疏、距离计算困难

2.多维缩放的核心思想是在低维空间，保持样本在高维空间的距离不变。假设 m 个样本在 d 维原始空间的距离矩阵为 D ，其第i行第j列的元素 d_{ij} 表示样本 x_i 和 x_j 之间的距离。多维缩放的目标是获得样本在 d' 维空间的表示 $Z \in R^{d' \times m}, d' \le d$ 。请你推导出 Z 的表达式。

3.令样本矩阵为 $X = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1d} \\ x_{21} & x_{22} & \cdots & x_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ x_{m1} & x_{m2} & \cdots & x_{md} \end{bmatrix}$,其中m为样本个数，d为空间维度。那么 XX^T 表示（内积矩阵），$X^T X$ 表示（协方差矩阵）。

4.请你从最近重构性推导主成分分析。

5.请写出求解主成分分析的方法。

6.如何选择主成分分析低空间的维度个数。

7.局部线性嵌入保持（邻域内样本之间的线性关系）不变。