正态分布

一、背景

第一个故事和概率论的发展密切相关，主角是棣莫弗(De Moivre) 和拉普拉斯(Laplace)。

拉普拉斯是个大科学家，被称为法国的牛顿；棣莫弗名气可能不算很大，不过大家应该都熟悉这个名字，因为我们在高中数学学复数的时候我们都学过棣莫弗定理：

$$(cos\,\theta + isin\,\theta)^n = cos\,(n\theta) + isin\,(n\theta)$$

古典概率论发源于赌博，惠更斯、帕斯卡、费马、贝努力都是古典概率的奠基人，他们那会研究的概率问题大都来自赌桌上，最早的概率论问题是赌徒梅累在 1654 年向帕斯卡提出的如何分赌金的问题。统计学中的总体均值之所以被称为期望(Expectation)，就是源自惠更斯、帕斯卡这些人研究平均情况下一个赌徒在赌桌上可以期望自己赢得多少钱。

概率论与数理统计课本上的一个有趣案例：

有一天一个哥们，也许是个赌徒，向棣莫弗提了一个和赌博相关的一个问题：A、B 两人在赌场里赌博，A、B 各自的获胜颜率是 p，q=1-p。赌 n 局，若 A 赢的局数 X>np，则 A 付给赌场 X-np 元，否付给赌场 np-X 元。问赌场挣钱的期望值是多少?

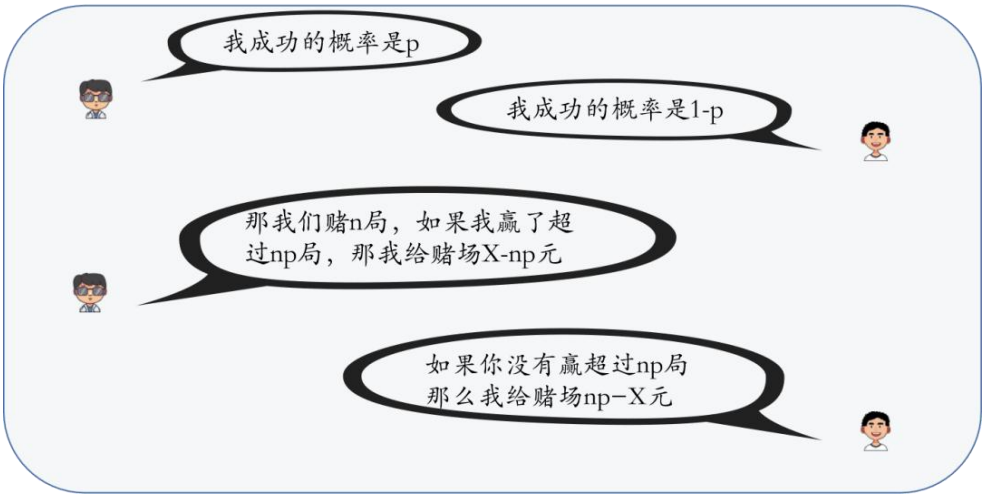

问题并不复杂，本质上是一个二项分布，最后求出的理论结果是

$$2npqb(n,p,np)$$

其中

$$b(n,p,i)=C_n^i p^i q^{n-i}$$

这是常见的二项概率。但是对具体的 n，要把这个理论结果实际计算出数值结果可不容易，因为其中的二项公式中有组合数。这就驱动 DeMoivre 寻找近似计算的方法计算。

同时，还有其他的一些问题，促使正态分布的发展：

与此相关联的另一个问题， 是遵从二项分布的随机变量$X\sim B(n,p)$， 求 X 落在二项分布中心点一定范围的概率$P_d=P(|X-np|\le d)$是多少。

对于$p=\frac{1}{2}$的情形， 棣莫弗做了一些计算并得到了一些近似结果，但是还不够漂亮，幸运的是棣莫弗和 Stirling 处在同一个时代，而且三人之间有联系，Stirling 公式是在数学分析中必学的一个重要公式（事实上斯特林公式的形式其实是棣莫弗最先发现的，但是斯特林改进了这个公式，改进的结果为涿莫弗所用）：

$$n!\approx\sqrt{2\pi n}(\frac{n}{e})^n$$

1733 年， 棣莫弗很快利用 Stirling 公式计算取得了重要的进展。考虑 n 是偶数的情形，今二项概率

$$b(i)=b(n,\frac{1}{2},i)=C_n^i(\frac{1}{2})^n$$

通过 Stirling 公式做一些简单的计算容易得到：

$$b(\frac{n}{2})\approx\sqrt{\frac{2}{\pi n}}\Rightarrow\frac{b(\frac{n}{2}+d)}{b(\frac{n}{2})}\approx exp\left\{\frac{-2\mathrm{d}^2}{\mathrm{n}}\right\}$$

于是有:

$$b(\frac{n}{2}+d)\approx\frac{2}{\sqrt{2\pi n}}exp\left\{\frac{-2\mathrm{d}^2}{\mathrm{n}}\right\}$$

使用上式的结果， 并在二项概率累加求和的过程中近似的使用定积分代替求和，很容易

就能得到:

$$P(|\frac{X}{n}-\frac{1}{2}|\leq\frac{c}{\sqrt{n}})=\sum_{i=-c\sqrt{n}}^{c\sqrt{n}}b\,(\frac{n}{2}+i)\approx\sum_{i=c}^{c\sqrt{n}}\frac{2}{\sqrt{2\pi n}}exp\left\{-\frac{2\mathrm{i}^2}{\mathrm{n}}\right\}$$
$$=\sum_{\frac{2i}{\sqrt{n}}-2c}^{2c}\frac{1}{\sqrt{2\pi}}exp\{-\frac{2}{\sqrt{n}}$$
$$\approx\int_{-2c}^{2c}\frac{1}{\sqrt{2\pi}}exp\left\{-\frac{x^2}{2}\right\}dx$$

至此，正态分布的密度函数的形式在积分公式中出现。这也就是在数理统计课本上学到的二项分布的极限分布是正态分布

以上是对 p=1/2 时的讨论。棣莫弗对 p≠1/2 也进行了计算，拉普拉斯进行了更多的分析，并把二项分布推广到了任意 p。产生了棣莫弗-拉普拉斯中心极限定理。

设随机变量

$$X_n(n=1,2,\ldots)$$

服从参数为 p 的二项分布则对任意的 X，恒有：

$$\lim_{n\to\infty}P\{\frac{X_n-X_p}{\sqrt{np(1-p)}}\leq x\}=\int_{-\infty}^{x}\frac{1}{\sqrt{2\pi}}exp\left\{-\frac{t^2}{2}\right\}dt$$

正态分布的密度形式首次发现是在棣莫弗-拉普拉斯的中心极限定理中。

棣莫弗给出他的发现后 40 年（大约是 1770），拉普拉斯建立了中心极限定理较一般的形式，中心极限定理后续又被其它数学家们推广到了其它任意分布的情形，而不限于二项分布。后续的统计学家发现，一系列的重要统计量，在样本量 N 趋于无穷的时候，其极限分布都有正态的形式，这构成了数理统计学中大样本理论的基础。

为解决天文学问题，避免经验化对结果的影响，勒让德在 1805 年发表了最小二乘法。随后高斯拓展了最小二乘法，把正态分布和最小二乘法联系在一起，并使得正态分布在统计误差分析中确立了自己的定位。

高斯采用极大似然法提出了误差分布为正态分布。

设真值为θ，而$x_1,x_2\ldots,x_n$为 n 次独立测量值，每次测量的误差为，假设误差e_i的密度函数为 f(e)， 则测量值的联合概率为 n 个误差的联合概率， 记为:

$$L(\theta)=L(\theta;x_1,x_2,\ldots,x_n)=\prod_{i=1}^{n}f\,(e_i)=\prod_{i=1}^{n}f\,(x_i-\theta)$$

但是高斯不采用贝叶斯的推理方式，而是直接取$L(\theta)$达到最大值的

$L(\theta)=L(\theta;x_1,x_2,\ldots,x_n)=\prod_{i=1}^{n}f\,(e_i)=\prod_{i=1}^{n}f\,(x_i-\theta)$

作为θ的估计值，即

$$\hat{\theta} = \underset{\hat{}}{\theta}(x_1, \ldots, x_n)\ \hat{\theta} = arg\max L(\theta)$$

现在我们把$L(\theta)$称为样本的似然函数，而得到的估计值$\hat{\theta}$称为极大似然估计。高斯首次给出了极大似然的思想，这个思想后来被统计学家 R.A.Fisher 系统的发展成为参数估计中的极大似然估计理论。

高斯把整个问题的思考模式倒过来：既然千百年来大家都认为算术平均是一个好的估计，那我就认为极大似然估计导出的就应该是算术平均。所以高斯猜测：误差分布导出的极大似然估计 = 算术平均值

然后高斯去找误差密度函数 f(e) 以迎合这一点。即寻找这样的颜率分布函数 f(e)，使得极大似然估计正好是算术平均。而高斯应用数学技巧求解这个函数 f，高斯证明)，所有的概率密度函数中，唯一满足这个性质的就是

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{x^2}{2\sigma^2}}$$

于是得到了正态分布的密度函数

$$N(0, \sigma^2)$$

进一步，高斯基于这个误差分布函数对最小二乘法给出了一个漂亮解释。对于每个误差e_i，有$e_i \sim N(0, \sigma^2)$，则$e_1, \ldots, \mathrm{e}_n\,(e_1, \ldots, e_n)$的联合概率分布为

$$\frac{1}{(\sqrt{2\pi}\sigma)^n} exp\left\{-\frac{x^2}{2\sigma^2}\right\}$$

要让这个概率最大，必须使得$\sum_{i=1}^{n} e_i^2$取得最小值，这正好是最小二乘法的要求。

高斯所拓展的最小二乘法成为了十九世纪统计学的最重要成就，它在十九世纪统计学的重要性就相当于十八世紀的微积分之于数学。而勒让德和高斯的最小二乘的发明权之争，成了数学史上仅次于牛顿、莱布尼茨微积分发明的争端。相比于勒让德 1805 给出的最小二乘法描述，高斯基于误差正态分布的最小二乘理论显然更高一筹，高斯的工作中既提出了极大似然估计的思想，又解决了误差的概率密度分布的问题，由此我们可以对误差的大小的影响进行统计度量了。

高斯的这项工作对后世的影响极大，而正态分布也因此被冠名高斯分布。

二、简介

正态分布曲线一种概率分布。正态分布是具有两个参数μ和σ^2的连续型随机变量的分布，第一参数μ是遵从正态分布的随机变量的均值，第二个参数σ^2是此随机变量的方差，所以正态分布记作N(μ，σ^2)。遵从正态分布的随机变量的概率规律为取μ邻近的值的概率大，而取离μ越远的值的概率越小；σ越小，分布越集中在μ附近，σ越大，分布越分散。正态分布的密度函数的特点是：关于μ对称，在μ处达到最大值，在正（负）无穷远处取值为0，在μ±σ处有拐点。它的形状是中间高两边低，图像是一条位于x轴上方的钟形曲线。当μ=0，σ^2=1时，称为标准正态分布，记为N（0，1）。μ维随机向量具有类似的概率规律时，称此随机向量遵从多维正态分布。多元正态分布有很好的性质，例如，多元正态分布的边缘分布仍为正态分布，它经任何线性变换得到的随机向量仍为多维正态分布，特别它的线性组合为一元正态分布。

正态分布表达式中有两个参数，即期望（均数）μ和标准差σ，σ^2为方差。

正态分布具有两个参数μ和σ^2的连续型随机变量的分布，第一参数μ是服从正态分布的随机变量的均值，第二个参数σ^2是此随机变量的方差，所以正态分布记作N(μ，σ^2)。

μ是正态分布的位置参数，描述正态分布的集中趋势位置。概率规律为取与μ邻近的值的概率大，而取离μ越远的值的概率越小。正态分布以X=μ为对称轴，左右完全对称。正态分布的期望、均数、中位数、众数相同，均等于μ。

σ描述正态分布资料数据分布的离散程度，σ越大，数据分布越分散，σ越小，数据分布越集中。也称为是正态分布的形状参数，σ越大，曲线越扁平，反之，σ越小，曲线越瘦高。

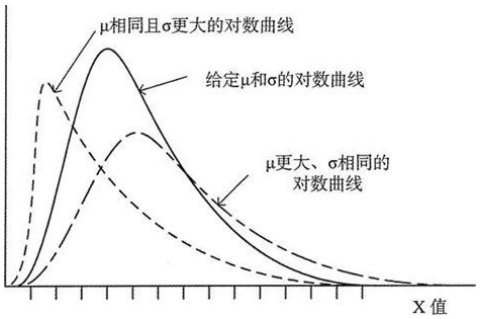

基本性质：

对称性：正态分布曲线以均数为中心，左右对称。

单峰性：正态分布曲线只有一个峰值，位于均数处。

有界性：正态分布曲线在均数处达到最高点，然后向两侧逐渐降低，但不会与横轴相交。

集中性：正态分布的高峰位于正中央，即均数所在的位置。

均匀变动性：正态分布曲线以均数为中心均匀向左右两侧下降。

期望值和标准差：正态分布的概率密度函数由期望值 μ 和标准差 σ 决定，μ 决定了位置，σ 决定了幅度。

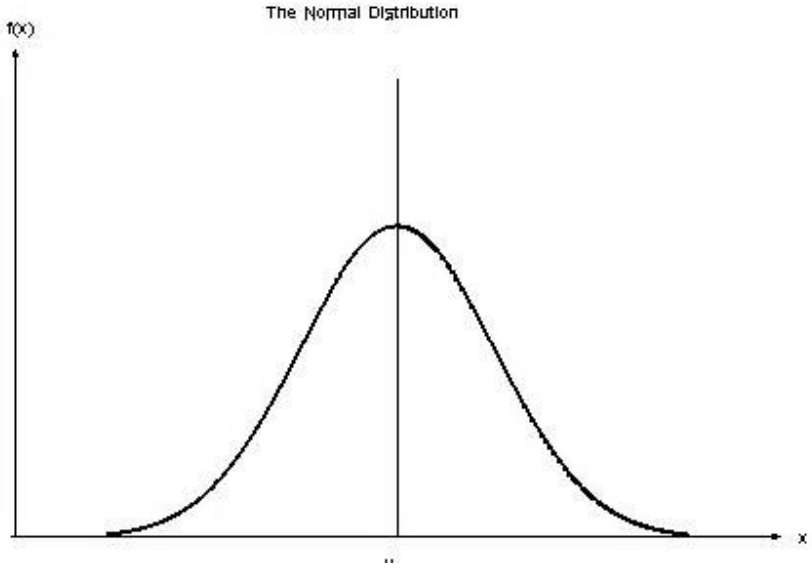

三、应用

正态分布在许多领域都有应用：

1. 统计学：正态分布在统计学中具有重要的作用，例如在假设检验、回归分析和样本推断等方面的应用。
2. 自然科学：在自然科学研究中，正态分布常常用于描述各种随机现象，如测量误差、实验数据等。
3. 金融学：正态分布在金融学中被广泛应用，用于描述股票价格、利率变动和投资回报等金融指标的波动性。
4. 生物学：正态分布在生物学中也有很多应用，例如描述身高、体重、血压等生理特征的分布。

5. 工程学：正态分布在工程学中用于描述和预测各种测量结果、质量控制和可靠性分析等。

6. 社会科学：正态分布在社会科学研究中的应用较多，例如在心理学、经济学和教育学等领域中，用于描述人群的智力水平、收入分布和考试成绩等。

7. 数据分析和机器学习：正态分布常常用于数据分析和机器学习中的建模和预测，例如线性回归和贝叶斯推断等方法。

应用中，最为重要的便是正态分布的 3σ 原则：

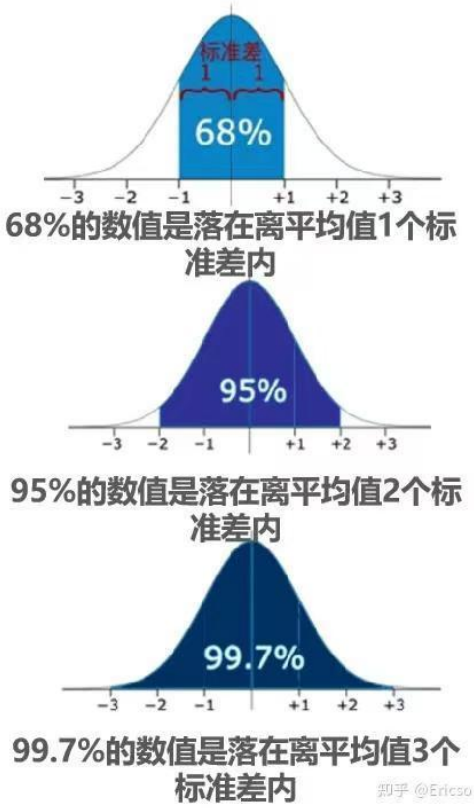

面积分布：

1.实际工作中，正态曲线下横轴上一定区间的面积反映该区间的例数占总例数的百分比，或变量值落在该区间的概率（概率分布）。不同范围内正态曲线下的面积可用公式计算。

2. 几个重要的面积比例：x 轴与正态曲线之间的面积恒等于 1。正态曲线下，横轴区间（μ－σ，μ＋σ）内的面积为 68.27%，横轴区间（μ-1.96σ，μ+1.96σ）内的面积为 95.00%，横轴区间（μ-2σ， μ+2σ）内的面积为 95.44%，横轴区间[0， μ+2σ）内的面积为 97.72%，横轴区间（μ-2.58σ， μ+2.58σ）内的面积为 99.00%，横轴区间（μ-3σ， μ+3σ）内的面积为 99.73%，距离平均值

3∂之外的值出现的概率为 P(|x-u| 3∂) = 0.003，属个别小概率事件。这个原则可以用来帮助我们处理数据中的异常值，假设一组检测数据只含有随机误差，计算处理该组数据得到标准差，然后按一定的概率确定一个区间，误差超过这个区间的就属于异常值。

3.如果数据不服从正态分布，也可以用远离平均值的多少倍标准差来描述。事实上，正态分布具有很强的普适性和实用性，在生活各处都能看到它的身影。

四、正态性检验

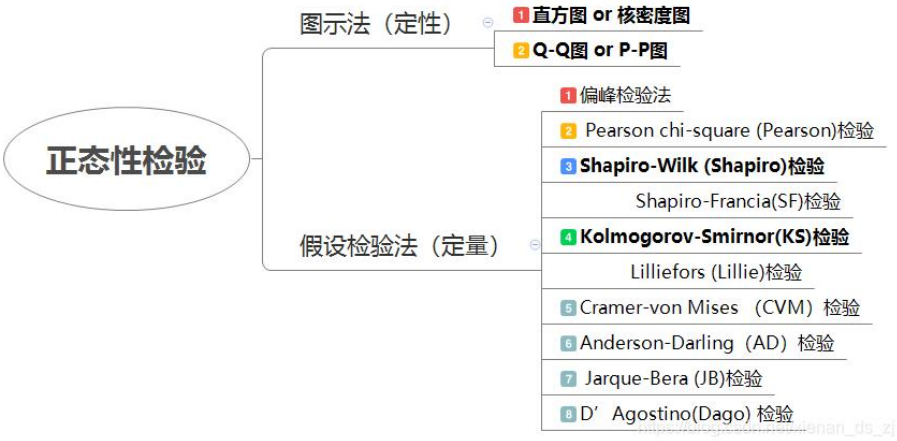

常用检验方法：

（1）图示法

1.直方图：通过绘制直方图可以直观地展示数据的分布情况，若数据呈现出中间高、两侧低的“钟形”分布，则认为数据服从正态分布。

2.P-P 图和 Q-Q 图：通过将实际数据的累积比例与正态分布的理论累积比例进行比较，若散点近似对角直线，则认为数据服从正态分布。

（2）统计检验法

1.Shapiro-Wilk 检验：适用于小样本数据，通过计算样本数据的统计量来判断其是否服从正态分布。

2.Kolmogorov-Smirnov 检验：适用于大样本数据，通过比较样本数据的累积分布函数与正态分布的理论累积分布函数来判断其是否服从正态分布。

3.Anderson-Darling 检验：基于经验累积分布函数（ECDF）的检验方法，适用于各种样本大小。

（3）描述法

1.偏度（Skewness）：描述数据分布的不对称性，当偏度≈0 时，认为数据近似服从正态分布。

2.峰度（Kurtosis）：描述数据分布的陡缓程度，当峰度≈0 时，认为数据近似服从正态分布。

五、参考文献：

[1] 何凤霞,马学俊. 基于 R 软件的正态性检验的功效比较[J].统计与决策,2012(18):17-19.

[2] 贾俊平. 统计学[M]. 第 6 版. 北京：中国人民大学出版社, 2014.12

[3] 高慧璇. 统计计算[M]. 北京：北京大学出版社, 1995.

[4] 李洪成. 数据的正态性检验方法及其统计软件实现 [J]. 统计与决策

[5]Rickjin (靳志辉). 正态分布的前世今生[Z], 2012.